

لینک گیت‌هاب:

<https://github.com/Armin11DSE/Web-Information-Retrieval-Projects>

تشخیص دوباره‌کاری در مقیاس کوچک

روش تشخیص دوباره‌کاری در مجموعه‌ای از ۱۰ سند کوچک را با استفاده از شینگل‌های ۳-گرم کلمات و معیار شباهت Jaccard پیاده‌سازی شده‌است. اسناد دارای true duplicate, near duplicate و اسنادی که به ظاهر شباهت زیادی دارند، اما در حقیقت جز این دسته‌ها قرار نمی‌گیرند، هستند.

محدودیت‌های مقیاس‌پذیری و نیاز به LSH + MinHash

روش فعلی با پیچیدگی زمانی $O(n^2)$ برای وب واقعی با میلیون‌ها صفحه غیرعملی است. MinHash این مشکل را با ایجاد "sketch"های فشرده حل می‌کند - امضاهای ثابت‌الاندازه که شباهت Jaccard را حفظ می‌کنند اما فضای ذخیره‌سازی را از هزاران شینگل به تنها ~ 100 مقدار هش کاهش می‌دهند. LSH سپس sketchهای مشابه را در سطلهای مشترک گروه‌بندی می‌کند و اجازه مقایسه تنها اسناد داخل همان سطل را می‌دهد، که پیچیدگی را از $O(n^2)$ به تقریباً $O(n)$ کاهش می‌دهد. این ترکیب کارایی حافظه (sketch) ها ~ 1 کیلوبایت در مقابل $100+$ کیلوبایت برای مجموعه شینگل‌های کامل، سرعت (مقایسه 100 مقدار هش به جای $1000+$ شینگل) و مقیاس‌پذیری (LSH بیش از ۹۹٪ مقایسه‌های غیرضروری را حذف می‌کند) را با حفظ دقت تشخیص فراهم می‌کند.