

لینک گیت‌هاب:

<https://github.com/Armin11DSE/Web-Information-Retrieval-Projects>

تحلیل شباهت اسناد با الگوریتم MinHash

روش‌شناسی

1. تولید داده

- تعداد اسناد: 20 متن کوتاه شبیه مقالات خبری
- محتوا: اسناد شامل موضوعات مختلف با برخی همپوشانی‌های عمدی

2. استخراج 3-گرام

- متن‌ها به حروف کوچک تبدیل و فاصله‌های اضافی حذف شدند
- از هر سند، شینگل‌های سه کلمه‌ای استخراج شد

3. پیاده‌سازی MinHash

- تعداد توابع هش: 100 تابع (بیش از حد مورد نیاز 50 تابع)
- روش هش‌سازی: استفاده از هش‌سازی جهانی با فرم $h(x) = (ax + b) \bmod p$
- تولید امضا: برای هر سند، امضای MinHash محاسبه شد

4. محاسبه شباهت

- روش اصلی: تخمین شباهت Jaccard با استفاده از امضاها
- روش کنترلی: محاسبه دقیق شباهت Jaccard برای مقایسه
- آستانه تشخیص: جفت‌هایی با شباهت بالای 70%

نتایج

دقت تخمین MinHash

- میانگین خطا: کمتر از 5%
- ضریب همبستگی: بالای 0.95 بین تخمین و مقدار واقعی
- حداکثر خطا: کمتر از 10%

تجسم‌سازی نتایج

1. نقشه حرارتی: ماتریس شباهت بین همه اسناد
2. گراف شبکه: نمایش اتصالات اسناد با شباهت بالا
3. نمودار پراکندگی: مقایسه دقت تخمین MinHash