

لینک گیت‌هاب:

<https://github.com/Armin11DSE/Web-Information-Retrieval-Projects>

تحلیل الگوریتم‌های MinHash و LSH برای تشخیص شباهت متون

الف) محاسبه امضای MinHash

- برای هر پاراگراف، مجموعه‌ای از shingle های سه‌کاراکتری تولید شد
- 100 تابع hash مستقل برای محاسبه امضای MinHash استفاده شد
- زمان محاسبه امضاها برای 500 سند ثبت گردید

ب) پیاده‌سازی LSH

- الگوریتم LSH با 20 باند و 5 ردیف در هر باند پیاده‌سازی شد
- آستانه شباهت 80% برای یافتن جفت‌های کاندید تعیین شد
- زمان جستجو و تعداد کاندیداهای یافته‌شده ثبت گردید

ج) مقایسه با روش Brute-Force

- تمام جفت‌های ممکن بررسی شدند
- شباهت واقعی Jaccard برای هر جفت محاسبه شد
- زمان اجرا و تعداد جفت‌های مشابه یافته‌شده ثبت گردید

د) تحلیل پیکربندی‌های مختلف باند

- 6 پیکربندی مختلف باند آزمایش شد: 4، 5، 10، 20، 25، 50 باند
- معیارهای Precision، Recall و زمان اجرا برای هر پیکربندی محاسبه شد

نتایج کلیدی

عملکرد زمانی

- LSH: میانگین زمان جستجو کمتر از 0.1 ثانیه
- Brute-Force: زمان اجرا ~ 5 ثانیه
- بهبود سرعت: تا 50 برابر سریع‌تر با LSH

دقت و فراخوانی

- بهترین پیکربندی: 20 باند با 5 ردیف در هر باند
- Precision: 85-95% در پیکربندی‌های بهینه
- Recall: 70-90% بسته به تنظیمات باند

تأثیر تعداد باندها

- باندهای کم (4-5): Recall بالا، Precision پایین، زمان اجرای بیشتر
- باندهای زیاد (25-50): Precision بالا، Recall پایین، زمان اجرای کم
- باندهای متوسط (10-20): تعادل مناسب بین Precision و Recall