

لینک گیت‌هاب:

<https://github.com/Armin11DSE/Web-Information-Retrieval-Projects>

۱. تشخیص Keyword Stuffing

- **هدف:** شناسایی تکرار افراطی کلمات کلیدی در محتوا
- **روش:** محاسبه نسبت فراوانی پرتکرارترین واژه به کل واژه‌ها
- **آستانه:** اگر نسبت < 0.15 باشد، محتوا به عنوان "Stuffed" برچسب‌گذاری می‌شود
- **نتیجه:** ابزار با موفقیت محتوای عادی و اسپم شده را تشخیص می‌دهد

۲. تشخیص Cloaking

- **هدف:** شناسایی ارائه محتوای متفاوت به کاربران و موتورهای جستجو
- **روش:** مقایسه پاسخ‌های دریافتی با User-Agent عادی و Googlebot
- **آستانه:** اگر اختلاف طول محتوا $< 10\%$ باشد، مشکوک محسوب می‌شود
- **خروجی:** گزارش شامل نمونه‌های محتوا و میزان اختلاف

چرا تراکم واژه به تنهایی سیگنال مطمئنی نیست؟

۱. **وابستگی به زمینه:** اسناد تخصصی طبیعتاً اصطلاحات خاص را تکرار می‌کنند
۲. **تأثیر طول محتوا:** محتوای کوتاه ممکن است نسبت بالایی بدون اسپم بودن داشته باشد
۳. **ساختار زبان:** برخی زبان‌ها ذاتاً تکرار بیشتری دارند
۴. **مثبت کاذب:** محتوای مشروع درباره موضوعات خاص ممکن است آستانه را فعال کند

* خروجی‌ها در notebook قابل مشاهده هستند. *