

لینک گیت‌هاب:

<https://github.com/Armin11DSE/Web-Information-Retrieval-Projects>

تحلیل‌گر ساختار وب‌سایت

این ابزار وب‌سایت‌ها را خزیده و ساختار آن‌ها را تحلیل می‌کند تا خصوصیات بنیادی وب را بررسی کند.

خروجی‌ها

۱. جدول تحلیل صفحات

برای هر صفحه موارد زیر محاسبه می‌شود:

- **طول محتوا:** تعداد کاراکتر متن قابل مشاهده
- **تعداد لینک خروجی:** تعداد `<a href>` در صفحه
- **داینامیک بودن:** آیا صفحه داینامیک است؟

۲. آمار کلی

کمینه، بیشینه و میانگین تمام معیارها

۳. ارزیابی گزاره‌ها

بررسی سه گزاره اصلی:

«محتوا ناهمگن و بدون طراحی متمرکز است»

- **روش:** بررسی تنوع طول محتوا و تعداد لینک‌ها
- **مطابقت:** اگر تنوع بالا باشد

«لینک‌ها ساختار گراف وب را می‌سازند»

- **روش:** بررسی وجود لینک‌های خروجی
- **مطابقت:** اگر میانگین لینک > 0

«صفحات می‌توانند به طور داینامیک ایجاد شوند»

- **روش:** تشخیص نشانه‌های داینامیک در URL
- **نشانه‌ها:** پارامترهای جستجو (?)، اعداد در مسیر، فایل‌های .php

تشخیص صفحات داینامیک

- وجود ؟ در URL
- اعداد در مسیر مانند /123/
- فایل‌های سمت سرور (.asp, .php)
- مسیرهای API و جستجو