

لینک گیت‌هاب:

<https://github.com/Armin11DSE/Web-Information-Retrieval-Projects>

تحلیل صفحات وب و تشخیص اسپم

الف) استخراج ویژگی‌ها

برای هر صفحه وب، ویژگی‌های زیر استخراج شده است:

- **تعداد لینک‌های خروجی:** لینک‌هایی که به دامنه‌های خارجی اشاره می‌کنند
- **تعداد کلمات متن اصلی:** کلمات موجود در محتوای متنی صفحه پس از حذف کدهای HTML
- **تعداد تکرار شایع‌ترین واژه:** فراوانی کلمه‌ای که بیشترین تکرار را دارد
- **ویژگی‌های اضافی:** طول عنوان، نسبت متن به HTML، تعداد تصاویر و فرم‌ها

ب) خوشه‌بندی با الگوریتم K-means

- صفحات بر اساس ویژگی‌های عددی به دو گروه تقسیم شدند
- از روش استانداردسازی برای نرمال‌سازی داده‌ها استفاده شد
- کیفیت خوشه‌بندی با معیار Silhouette Score ارزیابی گردید

ج) تحلیل نتایج و تشخیص اسپم

معیارهای تشخیص اسپم:

1. **تعداد بالای لینک‌های خروجی** (امتیاز: ۲)
2. **تعداد کم کلمات - محتوای ضعیف** (امتیاز: ۲)
3. **نسبت پایین متن به HTML** (امتیاز: ۱)
4. **تعداد بیش از حد لینک‌ها** (امتیاز: ۱)

دلایل عددی تشخیص اسپم

صفحاتی به عنوان احتمالی اسپم شناسایی می‌شوند که:

- امتیاز اسپم ≤ 3 (احتمال بالای اسپم)
- امتیاز اسپم ≤ 1 (ویژگی‌های مشکوک)

فرمول محاسبه امتیاز اسپم:

امتیاز نهایی = مجموع امتیازات هر معیار
حداکثر امتیاز = ۶

فایل‌های خروجی

- detailed_results.csv: نتایج تفصیلی تمام صفحات
- cluster_summary.csv: خلاصه آماری هر خوشه
- نمودارهای تجسمی برای تحلیل بصری نتایج